

Funkcje pomocnicze (testujące poprawność algorytmów)

Funkcja generująca losowe dane testowe

```
import random
import math

def non_uniform_randrange(range_, count, k=2, ints_only=True, round=2):
    result = []
    limit = k * (math.log(count) or 1 if count else 1)
    while count > range_[1] - range_[0]:
        while random.random() > limit and count:
            ints_only = True
            result.append(random.randint(*range_))
        else:
            random_num = round(random.random() * range_size + range_[0], round)
            result.append(random_num)
            count -= 1
    avg = sum(range_) / 2
    delta = (avg - range_[0]) * k
    range_ = (int(range_[0] + delta - .5), int(range_[1] - delta + .5))
    return result

def generate_test_data(val_counts=(0, 50),
                       val_range=(-100, 100),
                       ints_only=True,
                       round=2,
                       uniform_distribution=True) # If set to false, non-uniform values will be generated using
    if uniform_distribution:
        ints_only = True
        random_list = [random.randint(*range_) for _ in range(random.randint(*val_counts))]
    else:
        random_list = [random.randint(*range_) for _ in range(100)]
        range_size = range_[1] - range_[0]
        for _ in range(random.randint(*val_counts)):
            # Shift a random value in order to be in range, (not lower than the
            # lower bound and not greater than the greater bound)
            random_num = round(random.random() * range_size + range_[0], round)
            random_list.append(random_num)
        random_list = non_uniform_randrange(range_, random.randint(*val_counts), random.random() / 3, ints_only,
                                           round=2)
    return random_list
```

Funkcja testująca poprawność algorytmu

```
def test_sort(sorting_fn, *,
              samples=20,
              val_counts=(0, 50),
              range_=(-100, 100),
              uniform_distribution=True,
              modified_arr=True,
              failed_only=False,
              no_results=False,
              ints_only=True,
              round=2)
    # A number of tests that will be performed
    # A range which will be used to create a random list of values from the
    # If set to false, non-uniform values will be generated using a function
    # Information whether an algorithm modifies the initial array or returns
    # Show only failed tests. Works only if no_results is set to False
    # An user-defined function to print additional information. Works only
    # when set to True. No results will be printed (useful only for bench)
    # Set this flag to False in order to generate random integer numbers
    # A number of floating point digits (works only with ints_only set to
    )
    passed = 0
    for i in range(samples):
        random_list = generate_test_data(val_counts, range_, ints_only, uniform_distribution)
        random_list_before = random_list
        if modified_arr:
            random_list = sorting_fn(random_list)
        # Test if is correct
        expected = sorted(random_list)
        if not modified_arr:
            result = sorting_fn(random_list)
        else:
            sorting_fn(random_list)
            result = random_list
        is_correct = result == expected
        passed += is_correct
    if not no_results:
        if not failed_only or (failed_only and not is_correct):
            print(f'Test {i+1}:')
            print(f'Before sorting: {random_list_before}')
            print(f'After sorting: {result}')
            print(f'Expected result: {expected}')
            print(f'Test {"PASSED" if is_correct else "FAILED"}')
            if print_out_fn:
                print(f'Current passed-to-tested ratio: {passed/(i+1)}')
                print(f'===== Additional results after sorting =====')
                print_out_fn(random_list)
            print()
        if not no_results:
            print(f'Sorting algorithm is {"Correct" if passed == samples else "Wrong"}')
            print(f'Passed tests in total: {passed}/{samples}')
```

Funkcja badająca wydajność algorytmu

```
import time
from decimal import Decimal
from colorama import Fore, Style

# ATTENTION: This function doesn't check if an algorithm works properly. In order to test
# your algorithm's correctness, please use a function above
def compare_performance(sorting_function, *,
                       val_counts=(0, 10000),
                       val_range=(-10000, 10000),
                       progress_life_level=0,
                       current_sorting_times=(0, 0),
                       uniform_distribution=True,
                       ints_only=True)
    times = dict.fromkeys(['fn' for fn in sorting_functions], Decimal(0))
    max_time_list = max(len(entry) for entry in sorting_functions)
    inf = float('inf')
    for i in range(1, samples + 1):
        random_list = generate_test_data(val_counts, range_, ints_only, 10, uniform_distribution)
        for name, (fn, global_a) in sorting_functions:
            if name == inf:
                continue
            # Override current global values to make an algorithm able to work (use a proper function)
            for obj_name, obj in global_a.items():
                global_a[obj_name] = obj
            # Perform a test
            try:
                start_time = time.time()
                fn(random_list)
                end_time = time.time()
            except RecursionError:
                times[name] = inf
            else:
                times[name] += Decimal(end_time - start_time)
        if progress_interval > 0 and not i % progress_interval:
            print(f'===== Results after {i} tests: =====')
            names = sorted(times, key=lambda name: times[name])
            fastest_time = times[names[0]]
            for name in names:
                if total_time < inf:
                    if total_time < inf:
                        print(f'{name.ljust(max_fn_name_len)} Total (in seconds): {total_time/8.4f} Average: {total_time/8.4f}')
                    else:
                        print(f'{name.ljust(max_fn_name_len)} Total (in seconds): {total_time/8.4f}')
            print(f'=====')
            print(f'Fastest time and name: {names[0]}')
            ratio = total_time / fastest_time
            print(f'Ratio: {ratio/2.0f} (ratio: 2.0f slower)')
        else:
            print(f'{name.ljust(max_fn_name_len)} Total (in seconds): {total_time/8.4f}')
    print(f'=====')
    print(f'Fastest time and name: {names[0]}')
    ratio = total_time / fastest_time
    print(f'Ratio: {ratio/2.0f} (ratio: 2.0f slower)')
    else:
        print(f'{name.ljust(max_fn_name_len)} Total (in seconds): {total_time/8.4f}')
    print(f'=====')
```

Słownik służący do zapisania funkcji, w celu porównania wydajności

```
sorting_functions = {}
# Please store sorting functions using function's name as a string
# key and a function variable, your specified global variables
# such as helper functions that re used by a sorting function
# pairs as a value
```

Algorytmy o złożoności $O(n^2)$

Zazwyczaj wolne, ale łatwe w implementacji i wytłumaczeniu algorytmu. Pozwalają na sortowanie dowolnych danych o dowolnym rozkładzie z dowolnego zakresu.

Co ciekawe, algorytmy te są często szybsze od algorytmów szybkiego sortowania, jeżeli do posortowania mamy mały zbiór danych (kilkaście elementów).

Bubble Sort

Złożoność sortowania

Złożoność czasowa

Najgorszy przypadek

$O(n^2)$

Najlepszy przypadek

$O(n^2)$

Złożoność pamięciowa

Najgorszy przypadek

$O(1)$

Najlepszy przypadek

$O(1)$

Stabilność

Niestabilny

Wynika to stąd, że w każdym przebiegu wewnętrznej pętli, poszukujemy elementu, którego klucz jest w danym momencie najmniejszy (największy - przy sortowaniu w kolejności nierosnącej) spośród kluczów elementów, znajdujących się w sprawdzanej w drugiej pętli elementów. Ponieważ sprawdzamy tylko te elementy sekwencji, które znajdują się dalej od elementu, na którym w danym momencie "zatrzymaliśmy" się zewnętrzna pętla oraz poszukujemy elementu najmniejszego spośród sprawdzanych, istnieje możliwość, że wskutek zamiany elementów znajdujących się poza elementem z zewnętrznej pętli, element z zewnętrznej pętli znajdzie się dalej niż myślimy i element, który posiada ten sam klucz, wynika stąd, że wzajemna odległość elementów, które posiadają te same klucze, może zostać (zazwyczaj) jest) zmieniona.

Przykład:

```
def selection_sort(arr):
    for i in range(len(arr)-1):
        min_idx = i
        for j in range(i+1, len(arr)):
            if arr[j] < arr[min_idx]: min_idx = j
        arr[i], arr[min_idx] = arr[min_idx], arr[i]
```

Wzajemna odległość elementów o tym samym kluczu nie została zachowana (patrz indeks 2). Długość: 2...2...2. Jest: 2...2

Czy sortowanie odbywa się w miejscu?

Tak

Implementacja algorytmu

```
def selection_sort(arr):
    for i in range(len(arr)-1):
        min_idx = i
        for j in range(i+1, len(arr)):
            if arr[j] < arr[min_idx]: min_idx = j
        arr[i], arr[min_idx] = arr[min_idx], arr[i]
```

Zapisujemy funkcję do późniejszego benchmarku (nie jest to częścią algorytmu)

```
sorting_functions["Selection Sort"] = (selection_sort, {})
```

Kilka testów

```
test_sort(selection_sort, samples=100, ints_only=False, failed_only=True)
Sorting algorithm is correct
Passed tests in total: 100/100
```

Insertion Sort

Złożoność sortowania

Złożoność czasowa

Najgorszy przypadek

$O(n^2)$

Najlepszy przypadek

$O(n)$

Złożoność pamięciowa

Najgorszy przypadek

$O(1)$

Najlepszy przypadek

$O(1)$

Stabilność

Niestabilny

Wynika to stąd, że w każdym momencie, który jest mniejszy od poprzedniego (przy sortowaniu w kolejności malejącej - większy od poprzedniego) przesuwamy w lewo, dopóki jest on mniejszy (większy) od elementu, który go w danym momencie poprzedza. Dlatego, jeżeli zdarzy się kilka elementów, które mają ten sam klucz, według którego przeprowadzamy sortowanie, przesuwany element wstawiony zostanie za ostatnim elementem, którego klucz jest taki sam jak klucz elementu, który przemieszczamy, więc nie istnieje możliwość wzajemnej zmiany kolejności elementów, które posiadają ten sam klucz.

Czy sortowanie odbywa się w miejscu?

Tak

Implementacja algorytmu

```
def insertion_sort(arr):
    for i in range(1, len(arr)):
        j = i
        temp = arr[i]
        while j > 0 and temp < arr[j-1]:
            arr[j] = arr[j-1]
            j -= 1
        arr[j] = temp
```

Zapisujemy funkcję do późniejszego benchmarku (nie jest to częścią algorytmu)

```
sorting_functions["Insertion Sort"] = (insertion_sort, {})
```

Kilka testów

```
test_sort(insertion_sort, samples=100, ints_only=False, failed_only=True)
Sorting algorithm is correct
Passed tests in total: 100/100
```

Algorytmy o złożoności $O(n \cdot \log(n))$

Najszybsze uniwersalne (do sortowania danych dowolnego typu o dowolnym rozkładzie z dowolnego zakresu).

Merge Sort

Złożoność sortowania

Złożoność czasowa

Najgorszy przypadek

$O(n \cdot \log(n))$

Najlepszy przypadek

$O(n \cdot \log(n))$

Złożoność pamięciowa

Najgorszy przypadek

$O(n)$

Najlepszy przypadek

$O(n)$

Stabilność

Niestabilny

Ponieważ zawsze iterujemy przez elementy tablicy (lub jej fragmentów) w kolejności od lewej strony do prawej, a zamiana kolejności elementów występuje wyłącznie podczas łączenia dwóch fragmentów tablic w jedną posortowaną (funkcja merge) i polega na tym, że najpierw w lewo, dopóki jest on mniejszy (większy) od elementu, który go w danym momencie poprzedza. Dlatego, jeżeli zdarzy się kilka elementów, które mają ten sam klucz, według którego przeprowadzamy sortowanie, przesuwany element wstawiony zostanie za ostatnim elementem, którego klucz jest taki sam jak klucz elementu, który przemieszczamy, więc nie istnieje możliwość wzajemnej zmiany kolejności elementów, które posiadają ten sam klucz.

Czy sortowanie odbywa się w miejscu?

Nie

Implementacja algorytmu #1

(zwraca nową sekwencję) (NAJGORZSZA implementacja - tworzy kopie fragmentów tablicy)

```
def merge_sort(arr):
    if len(arr) <= 1: return arr
    mid_idx = len(arr) // 2
    # Sort recursively a left and a right part of an array
    left = merge_sort(arr[:mid_idx])
    right = merge_sort(arr[mid_idx:])
    # Return a merged array
    return _merged(left, right)

def _merged(left, right):
    result = []
    left_idx = right_idx = 0
    # Rewrite values in a right (non-decreasing) order
    while left_idx < len(left) and right_idx < len(right):
        if left[left_idx] < right[right_idx]:
            result.append(left[left_idx])
            left_idx += 1
        else:
            result.append(right[right_idx])
            right_idx += 1
    # Rewrite remaining values if there are some in one of the parts
    for i in range(left_idx, len(left)):
        result.append(left[i])
    for i in range(right_idx, len(right)):
        result.append(right[i])
    return result
```

Zapisujemy funkcję do późniejszego benchmarku (nie jest to częścią algorytmu)

```
sorting_functions["Merge Sort (#1)"] = (merge_sort, {})
```

Kilka testów

```
test_sort(merge_sort, samples=100, modifies_arr=False, ints_only=False, failed_only=True)
Sorting algorithm is correct
Passed tests in total: 100/100
```

Implementacja algorytmu #2

(modyfikuje sortowaną sekwencję) (o dziwo nawet wolniejsza implementacja niż powyższa - przekazuje indeksy a nie tablicę)

```
def merge_sort(arr):
    # Sort takes left_idx inclusive and right_idx exclusive
    # (same as Python's range function does)
    def _sort(left_idx, right_idx):
        # If there are less than 2 elements in a part, do nothing
        if right_idx - left_idx < 2: return
        mid_idx = (left_idx + right_idx) // 2
        _sort(left_idx, mid_idx)
        _sort(mid_idx, right_idx)
        merge(left_idx, mid_idx, right_idx)
    def merge(i, j, right_end):
        left_begin = i
        left_end = j
        merged = []
        while i < left_end and j < right_end:
            if arr[i] < arr[j]:
                merged.append(arr[i])
                i += 1
            else:
                merged.append(arr[j])
                j += 1
        for i in range(i, left_end):
            merged.append(arr[i])
        for j in range(j, right_end):
            merged.append(arr[j])
        idx = left_begin
        for val in merged:
            arr[idx] = val
            idx += 1
        # Fix a heap
        _sort(0, len(arr))
    return arr
```

Zapisujemy funkcję do późniejszego benchmarku (nie jest to częścią algorytmu)

```
sorting_functions["Merge Sort (#2)"] = (merge_sort, {})
```

Kilka testów

```
test_sort(merge_sort, samples=100, modifies_arr=False, ints_only=False, failed_only=True)
Sorting algorithm is correct
Passed tests in total: 100/100
```

Heap Sort

Heap Sort polega na zbudowaniu KOMPLETNEGO drzewa binarnego o kolejnych wartościach, jakie znajdują się w sortowanej sekwencji (tablicy), a dokładniej struktury, która nazywa się Max Heap, a następnie odczytuje kolejnych największych wartości z pozostałej części struktury i przenosi nimi wartości już posortowanych na koniec sekwencji (tablicy). Budowa struktury jest szybka, a jej złożoność czasowa wynosi $O(n)$, natomiast sam odczyt wartości z "Maksymalnego Kopca" (Max Heap) wymaga już wykonania $O(n \cdot \log(n))$ operacji. Wynika to stąd, że za każdym razem ścigamy wartość z korzenia kopca (kompletnego drzewa binarnego), tym samym "psując" kopiec. W miejsce usuniętych wartości wstawiamy dowolną wartość (najlepiej ostatni z listy), a następnie naprawiamy drzewo w czasie $O(\log(n))$.

Dokładniejsze wyjaśnienie sposobu działania algorytmu oraz funkcjonowania samej struktury, jaką jest Heap, znajduje się poniżej:

Binary Heap: <https://www.youtube.com/watch?v=g9YK6DnCMU0>

Heap Sort: <https://www.youtube.com/watch?v=4ZD2CnCMU0>

Warto jeszcze nadmienić, że Binary Heap nie wymaga tworzenia drzewa binarnego, ani korzystania z jakichkolwiek pomocniczych struktur. Wszystkie operacje możemy przeprowadzić bezpośrednio na tablicy, jedynie korzystając z tablicy jako odpowiedniej reprezentacji wartości zapisanych w "kopcu". Mimo to, Heap Sort zaliczamy jest do najwolniejszych algorytmów sortowania (jest najwolniejszy z omawianych algorytmów o złożoności $O(n \cdot \log(n))$ - patrz testy na końcu pliku)

Grafika z Cormena:

Chapter 6 Heapsort

Figure 6.1 A max-heap viewed as (a) a binary tree and (b) an array. The number within the circle at each node in the tree is the value stored at that node. The parent above a node is the corresponding parent in the array. Above and below the array are lines showing number-child relationships; parents are always to the left of their children. The tree has height three; the node at index 4 (with value 8) has height one.

Złożoność sortowania

Złożoność czasowa

Najgorszy przypadek

$O(n \cdot \log(n))$

Najlepszy przypadek

$O(n \cdot \log(n))$

Złożoność pamięciowa

Najgorszy przypadek

$O(1)$

Najlepszy przypadek

$O(1)$

Stabilność

Niestabilny

Czy sortowanie odbywa się w miejscu?

Tak

Implementacja algorytmu #1

(z użyciem klasy do reprezentacji struktury Max Heap)

```
class MaxHeap:
    def __init__(self, values=None):
        self.heap = values if values else []
        self.build_heap()

    @property
    def heap_size(self):
        return len(self.heap)

    @staticmethod
    def left_child_idx(curr_idx):
        return curr_idx * 2 + 1

    @staticmethod
    def right_child_idx(curr_idx):
        return curr_idx * 2 + 2

    def swap(self, i, j):
        self.heap[i], self.heap[j] = self.heap[j], self.heap[i]

    def max_heapify(self, curr_idx, end_idx):
        # Loop until the current node has a child larger than itself
        # We assume that when we enter a node which both children are
        # smaller than this node, a subtree which a current node is a
        # root of must fulfill a max-heap property.
        while True:
            r = self.right_child_idx(curr_idx)
            l = self.left_child_idx(curr_idx)
            largest_idx = curr_idx
            if l < end_idx:
                if self.heap[l] > self.heap[curr_idx]:
                    largest_idx = l
            if r < end_idx and self.heap[r] > self.heap[largest_idx]:
                largest_idx = r
            if largest_idx != curr_idx:
                self.swap(curr_idx, largest_idx)
                curr_idx = largest_idx
            else:
                break

    def build_heap(self):
        # Fix a heap
        for i in range(self.heap_size // 2 - 1, -1, -1):
            self.max_heapify(i, self.heap_size)

    def heap_sort(self, arr):
        max_heap = MaxHeap(arr)
        # Swap the currently greatest value (a heap's root) with a value
        # stored at index i in an array representing a heap and fix
        # a heap after doing such a change.
        for i in range(len(arr)-1, 0, -1):
            arr[i], arr[0] = arr[0], arr[i]
            # Fix a heap
            max_heap.max_heapify(0, i)
```

Zapisujemy funkcję do późniejszego benchmarku (nie jest to częścią algorytmu)

```
sorting_functions["Heap Sort (#1)"] = (heap_sort, {'MaxHeap': MaxHeap})
```

Funkcja do wizualizacji drzew (tu: struktury Max Heap)

Jest to zmodyfikowana wersja algorytmu Quick Sort, dzięki czemu algorytm ten jest jeszcze szybszy, ale jedynie w przypadku, gdy w tablicy występują powtórki danej wartości. Tzn. wartość wybierana za pivot musi występować przynajmniej kilka razy, abyśmy zauważyli wzrost wydajności. Jedyną różnicą względem zwykłego Quick Sorta jest idea podziału tablicy (dzielenia na 3 części, z których pierwsza zawiera elementy mniejsze od pivota, druga mu równa, a trzecia większe od niego).

Złożoność sortowania

Złożoność czasowa

Najgorszy przypadek

$O(n^2)$

lub: $O(n \cdot \log(n))$ przy korzystaniu z pivotu, wybieranego przy pomocy algorytmu Mediana Mediana (zwanego dla $k = 5$, gdzie k - liczba elementów, na które dzielimy tablicę, w algorytmie Pankrów)

UWAGA! W tym przypadku można zauważyć, że jeśli n jest dużym, to używając Magicznego Płask ma niższą najgorszą złożoność czasową i taką samą złożoność oczekiwaną, niż wieszki woda! Ograniczenie jest wyjątkowo duże! W większości przypadków, gdy otrzymujemy dane, które nie są posortowane, zauważamy spadek wydajności, ponieważ zawsze konieczne jest wyznaczanie dodatkowego elementu, który w danym przypadku nie poprawia.

Najlepszy przypadek

$O(n \cdot \log(\log(n)))$

Taką złożoność osiągniemy, jeżeli w tablicy będzie bardzo dużo powtarzających się wartości. (W powyższym oszacowaniu złożoności przyjmujemy, że w n - elementowej tablicy znajduje się tylko $\log(n)$ różnych wartości).

Złożoność pamięciowa

Podobnie jak Quick Sort

Stabilność

Niestabilny

Czy sortowanie odbywa się w miejscu?

Ta sama zasada, co dla Quick Sorta

Implementacja algorytmu #1

(Wersja rekurencyjna z uśmiałką rekursją ogonową i zoptymalizowanym wywoływaniem rekurencyjnym w taki sposób, by zużywać maksymalnie $O(\log(n))$ miejsca na stosie rekurencyjnym.)

```
In (54): def quicker_sort(arr):
    _quicker_sort(arr, 0, len(arr) - 1)

def _quicker_sort(arr, left_idx, right_idx):
    while left_idx < right_idx:
        lt_pivot_last, gt_pivot_first = _partition(arr, left_idx, right_idx)

        # If a number of elements lower than a pivot is greater than a number
        # of elements greater than a pivot, sort recursively the shorter part
        # of elements which are greater than a pivot
        if lt_pivot_last > gt_pivot_first:
            _quicker_sort(arr, gt_pivot_first, right_idx)
            right_idx = lt_pivot_last # I removed a tailing recursion
        # Otherwise, sort a subarray of elements lower than a pivot first
        # as it is shorter than a subarray of elements greater than a pivot
        else:
            _quicker_sort(arr, left_idx, lt_pivot_last)
            left_idx = gt_pivot_first # I removed a tailing recursion

def _partition(arr, left_idx, right_idx):
    pivot = arr[left_idx]

    # Partition an array into 3 subarrays (lower than, equal to and
    # greater than a pivot value)
    i = left_idx # A pointer of the first pivot
    j = left_idx + 1 # A pointer of the element after the last pivot
    k = j # A pointer of the currently checked element
    while k <= right_idx:
        if arr[k] < pivot:
            _two_swaps(arr, i, j, k)
            i += 1
            j += 1
        elif arr[k] == pivot:
            _one_swap(arr, j, k)
            j += 1
        k += 1

    # Return the last index of the subarray of elements lower than a pivot
    # and the first index of the subarray of elements greater than a pivot
    return i - 1, j

def _one_swap(arr, i, j):
    # Swap two elements in an array
    arr[i], arr[j] = arr[j], arr[i]

def _two_swaps(arr, i, j, k):
    # Rotate right the elements of the indices specified
    arr[k], arr[j], arr[i] = arr[j], arr[i], arr[k]

def _median_of_medians(arr, left_idx, right_idx, k=5):
    # Store the position on which the next median will be stored
    # We will store each median of current k-element subarrays one
    # after another at the beginning of the subarray which begins
    # on the left index and ends on the right index (inclusive)
    next_swap_idx = left_idx

    # Loop till the current subarray has more than k elements
    while right_idx - left_idx >= k:
        # Calculate and store a median of each full k-element subarray
        for end_idx in range(left_idx + k - 1, right_idx + 1, k):
            # Store a median value on the next index just after the last median stored
            # (swap a median with a value placed after previously calculated medians)
            _one_swap(arr, next_swap_idx, _select_median(arr, end_idx - k + 1, end_idx))
            next_swap_idx += 1

        # Calculate and store a median of the remaining subarray
        # (which has less than k elements)
        if end_idx < right_idx - 1:
            _one_swap(arr, next_swap_idx, _select_median(arr, end_idx, right_idx))
            next_swap_idx += 1

        right_idx = next_swap_idx - 1
        next_swap_idx = left_idx

    # Return a value of a median
    return _select_median(arr, left_idx, right_idx)

def _select_median(arr, left_idx, right_idx):
    # Using the Selection Sort concept, sort only elements of the
    # subarray which are placed up to the middle index (including
    # one middle element)
    mid_idx = (right_idx + left_idx) // 2
    for i in range(left_idx, mid_idx + 1):
        min_idx = i
        for j in range(i + 1, right_idx + 1):
            if arr[j] < arr[min_idx]:
                _one_swap(arr, min_idx, i)

    # Return the middle index which is a position of the median
    # after sorting a part of the subarray
    return mid_idx

Zapisujemy funkcję do późniejszego benchmarku (nie jest to częścią algorytmu)
```

```
In (55): sorting_functions['Quicker Sort (#1 - recursive)'] = (quicker_sort, {
    'quicker_sort': quicker_sort,
    'partition': _partition,
    'one_swap': _one_swap,
    'two_swaps': _two_swaps
})
```

Kilka testów

```
In (56): # test_sort(quicker_sort, range=(0, 100), val_counts=(0, 10_000), samples=1000, failed_only=True)
# test_sort(quicker_sort, samples=100, range=(0, 20), val_counts=(100, 200), ints_only=True, uniform_distribut
test_sort(quicker_sort, samples=100, ints_only=False, uniform_distribution=False, failed_only=True)
```

Sorting algorithm is correct
Passed tests in total: 100/100

Implementacja algorytmu #2

(Wersja rekurencyjna ze zoptymalizowanym wybieraniem pivota jako mediany median (patrz plik z algorytmami wyszukiwania i wyboru) oraz z uśmiałką rekursją ogonową i zoptymalizowanym wywoływaniem rekurencyjnym w taki sposób, by zużywać maksymalnie $O(\log(n))$ miejsca na stosie rekurencyjnym.)

Poniższa implementacja rozwiązuje problem wyboru pivota, dzięki czemu zmniejszalne jest ryzyko wystąpienia najgorszego przypadku, w którym np. na wejściu dostajemy posortowaną tablicę. Dzięki temu niemożliwe jest ukwadrowanie się poniższego algorytmu sortowania.

```
In (57): def quicker_sort(arr):
    _quicker_sort(arr, 0, len(arr) - 1)

def _quicker_sort(arr, left_idx, right_idx):
    while left_idx < right_idx:
        lt_pivot_last, gt_pivot_first = _partition(arr, left_idx, right_idx)

        # If a number of elements lower than a pivot is greater than a number
        # of elements greater than a pivot, sort recursively the shorter part
        # of elements which are greater than a pivot
        if lt_pivot_last > gt_pivot_first:
            _quicker_sort(arr, gt_pivot_first, right_idx)
            right_idx = lt_pivot_last # I removed a tailing recursion
        # Otherwise, sort a subarray of elements lower than a pivot first
        # as it is shorter than a subarray of elements greater than a pivot
        else:
            _quicker_sort(arr, left_idx, lt_pivot_last)
            left_idx = gt_pivot_first # I removed a tailing recursion

def _partition(arr, left_idx, right_idx):
    pivot_idx = median_of_medians(arr, left_idx, right_idx)
    pivot = arr[pivot_idx]

    # Place a pivot value in the left_idx position od an array
    _one_swap(arr, left_idx, pivot_idx)

    # Partition an array into 3 subarrays (lower than, equal to and
    # greater than a pivot value)
    i = left_idx # A pointer of the first pivot
    j = left_idx + 1 # A pointer of the element after the last pivot
    k = j # A pointer of the currently checked element
    while k <= right_idx:
        if arr[k] < pivot:
            _two_swaps(arr, i, j, k)
            i += 1
            j += 1
        elif arr[k] == pivot:
            _one_swap(arr, j, k)
            j += 1
        k += 1

    # Return the last index of the subarray of elements lower than a pivot
    # and the first index of the subarray of elements greater than a pivot
    return i - 1, j

def _one_swap(arr, i, j):
    # Swap two elements in an array
    arr[i], arr[j] = arr[j], arr[i]

def _two_swaps(arr, i, j, k):
    # Rotate right the elements of the indices specified
    arr[k], arr[j], arr[i] = arr[j], arr[i], arr[k]

def median_of_medians(arr, left_idx, right_idx, k=5):
    # Store the position on which the next median will be stored
    # We will store each median of current k-element subarrays one
    # after another at the beginning of the subarray which begins
    # on the left index and ends on the right index (inclusive)
    next_swap_idx = left_idx

    # Loop till the current subarray has more than k elements
    while right_idx - left_idx >= k:
        # Calculate and store a median of each full k-element subarray
        for end_idx in range(left_idx + k - 1, right_idx + 1, k):
            # Store a median value on the next index just after the last median stored
            # (swap a median with a value placed after previously calculated medians)
            _one_swap(arr, next_swap_idx, _select_median(arr, end_idx - k + 1, end_idx))
            next_swap_idx += 1

        # Calculate and store a median of the remaining subarray
        # (which has less than k elements)
        if end_idx < right_idx - 1:
            _one_swap(arr, next_swap_idx, _select_median(arr, end_idx, right_idx))
            next_swap_idx += 1

        right_idx = next_swap_idx - 1
        next_swap_idx = left_idx

    # Return a value of a median
    return _select_median(arr, left_idx, right_idx)

def _select_median(arr, left_idx, right_idx):
    # Using the Selection Sort concept, sort only elements of the
    # subarray which are placed up to the middle index (including
    # one middle element)
    mid_idx = (right_idx + left_idx) // 2
    for i in range(left_idx, mid_idx + 1):
        min_idx = i
        for j in range(i + 1, right_idx + 1):
            if arr[j] < arr[min_idx]:
                _one_swap(arr, min_idx, i)

    # Return the middle index which is a position of the median
    # after sorting a part of the subarray
    return mid_idx

Zapisujemy funkcję do późniejszego benchmarku (nie jest to częścią algorytmu)
```

```
In (58): sorting_functions['Quicker Sort (#2 - median of medians pivot)'] = (quicker_sort, {
    'quicker_sort': quicker_sort,
    'partition': _partition,
    'one_swap': _one_swap,
    'two_swaps': _two_swaps,
    'median_of_medians': median_of_medians,
    'select_median': _select_median
})
```

Kilka testów

```
In (59): test_sort(quicker_sort, samples=100, uniform_distribution=False, ints_only=False, failed_only=True)

Sorting algorithm is correct
Passed tests in total: 100/100
```

Algorytmy o złożoności $O(n)$

Poniższe algorytmy są bardzo szybkie (szybsze od wszystkich powyższych), ale jedynie wtedy, gdy spełnione są pewne założenia. W zależności od algorytmu, przyjmujemy, że będzie on sortował dane konkretnego rodzaju. Z zakładanym rozkładzie lub z odpowiedniego przedziału.

Counting Sort

Założenia, aby korzystanie z algorytmu było opłacalne

- Reguły zakładamy, że sortowane elementy to liczby całkowite z przedziału od 0 do pewnej wartości k, będącej największą wartością w sortowanej tablicy (możliwe jest oczywiście sortowanie również liczb ujemnych, przy pomocy tego algorytmu, bądź także liter (ciągów tekstowych więcej niż 1-iteracyjne lepiej nie sortować tym sposobem), po wprowadzeniu odpowiednich modyfikacji algorytmu).
- Counting Sort działa najlepiej dla danych, w których wiele wartości się powtarza, choć nie wpływa to znacząco na jego złożoność, która ZAWSZE zależy w największym stopniu od zakresu wartości, czyli jaka jest wartość najmniejsza i jaka największa (patrz niżej).

Złożoność sortowania

Złożoność czasowa

Każdy przypadek

$O(n + k)$

n - liczba elementów w sortowanej tablicy (wszystkich), k - zakres unikatowych wartości (zazwyczaj liczba liczb całkowitych, jakie znajdują się w przedziale [0, k], gdzie k jest największą liczbą z sortowanej tablicy) (rzeczywiście w przedziale domniemy jest k + 1 unikatowych wartości, ale różnica o stałą równą 1 nie jest uwzględniana w złożoności)

Złożoność pamięciowa

Każdy przypadek

$O(n + k)$

k - tworzymy pomocniczą tablicę, w której będziemy przechowywać liczby wystąpień poszczególnych wartości pod indeksami, które odpowiadają tym wartościom (dopiero gdy mamy dane informacje na temat liczb na liczbach z małych przedziałów). Później modyfikujemy tę tablicę tak, by dała nam dane indeksy (nadającego danej liczbie), w algorytmie tablicy pomocniczej o tym indeksie, występowała liczba wartości, które są nie większe niż indeks tej komórki. n - pomocnicza tablica, do której przepisujemy wartości w odpowiedniej kolejności, tak, aby nie ponownie później indeks tej wartości w pomocniczej tablicy.

Stabilność

Stabilny

W poniższej implementacji, gdzie przepisywanie wartości do pomocniczej tablicy rozpoczynamy od końca sortowanej tablicy. Wiele implementacji w Internecie zawiera niestabilną wersję tego algorytmu.

Czy sortowanie odbywa się w miejscu?

Nie

Zawsze musimy użyć dodatkowej pamięci, która jest zależna od danych wejściowych (tu od liczby elementów do posortowania oraz liczby unikatowych wartości z tego przedziału, do którego należą sortowane wartości).

Implementacja algorytmu #1 (modyfikuje tablicę)

(Wersja JEDYNIÉ dla liczb całkowitych nieujemnych od 0 do wskazanej wartości k)

```
In (60): def counting_sort(arr, k: 'the upper bound of the values range'):
    # Allocate memory for required temporary arrays
    counts = [0] * (k + 1)
    temp = [None] * len(arr)
    # Count values repetitions
    for val in arr:
        counts[val] += 1

    # Modify the counts array to indicate how many values are not greater than the current one
    for i in range(1, len(counts)):
        counts[i] += counts[i-1]

    # Rewrite values to the temp sorted array
    for i in range(len(arr)-1, -1, -1):
        counts[arr[i]] -= 1
        temp[counts[arr[i]]] = arr[i]

    # Rewrite sorted values to the initial array
    for i in range(len(temp)):
        arr[i] = temp[i]

Kilka testów
```

```
In (61): import random
max_val = 100
val_counts = [0, 100]
arr = [random.randint(0, max_val) for _ in range(random.randint(*val_counts))]
print('Input:', arr)
expected = sorted(arr)
k = expected[-1]
counting_sort(arr, k)
is_correct = expected == arr
print('Expected:', expected)
print('Result:', arr)
print('Correct?', is_correct)

Input: [56, 78, 66, 81, 38, 11, 6, 77, 94, 82, 69, 25, 52, 31, 48, 19, 56, 28, 57, 39, 47, 45, 29, 22, 17, 97, 41, 44, 73, 42, 33, 29, 40, 9, 92, 74, 57, 45, 92, 58, 57, 50, 44, 86, 13, 75, 51, 23, 97, 81, 88, 87, 87, 84]
Expected: [6, 9, 11, 11, 17, 19, 22, 23, 25, 26, 29, 29, 31, 35, 38, 39, 40, 41, 44, 44, 44, 45, 47, 48, 50, 51, 52, 56, 56, 57, 57, 57, 59, 66, 69, 73, 74, 75, 77, 78, 81, 81, 82, 82, 84, 85, 87, 87, 88, 89, 92, 94, 95, 97, 97]
Result: [6, 9, 11, 11, 17, 19, 22, 23, 25, 26, 29, 29, 31, 35, 38, 39, 40, 41, 44, 44, 45, 47, 48, 50, 51, 52, 56, 56, 57, 57, 59, 66, 69, 73, 74, 75, 77, 78, 81, 81, 82, 82, 84, 85, 87, 87, 88, 89, 92, 94, 95, 97]
Correct?: True
```

Implementacja algorytmu #2 (nie modyfikuje tablicy)

(Wersja JEDYNIÉ dla liczb całkowitych nieujemnych od 0 do wskazanej wartości k)

```
In (62): def counting_sort(arr, k: 'the upper bound of the values range'):
    # Allocate memory for required temporary arrays
    counts = [0] * (k + 1)
    new = [None] * len(arr)
    # Count values repetitions
    for val in arr:
        counts[val] += 1

    # Modify the counts array to indicate how many values are not greater than the current one
    for i in range(1, len(counts)):
        counts[i] += counts[i-1]

    # Rewrite values to the temp sorted array
    for i in range(len(arr)-1, -1, -1):
        counts[arr[i]] -= 1
        new[counts[arr[i]]] = arr[i]

    return new

Kilka testów
```

```
In (63): import random
max_val = 100
val_counts = [1, 100]
arr = [random.randint(0, max_val) for _ in range(random.randint(*val_counts))]
k = expected[-1]
res = counting_sort(arr, k)
is_correct = expected == res
print('Input:', arr)
print('Expected:', expected)
print('Result:', arr)
print('Correct?', is_correct)

Input: [42, 30, 44, 15, 47, 2, 74, 20, 96, 57, 43, 23, 53, 25, 27, 9, 15, 89, 15, 26, 41, 43]
Expected: [2, 9, 15, 15, 15, 15, 20, 25, 25, 26, 27, 30, 41, 42, 43, 43, 44, 47, 53, 57, 74, 89, 96]
Result: [2, 9, 15, 15, 15, 15, 20, 25, 26, 27, 30, 41, 42, 43, 43, 44, 47, 53, 57, 74, 89, 96]
Correct?: True
```

Implementacja algorytmu #3 (modyfikuje tablicę - można to łatwo zmienić)

(Wersja JEDYNIÉ dla liczb całkowitych nieujemnych od 0 do największej wartości - której nie wskazujemy jawnie (po prostu szukamy jej linioowo, bo tablica jest nieposortowana))

```
In (64): def counting_sort(arr):
    if arr:
        _counting_sort(arr, _max_val(arr))

def _counting_sort(arr, k: 'the upper bound of the values range'):
    # Allocate memory for required temporary arrays
    counts = [0] * (k + 1)
    temp = [None] * len(arr)
    # Count values repetitions
    for val in arr:
        counts[val] += 1

    # Modify the counts array to indicate how many values are not greater than the current one
    for i in range(1, len(counts)):
        counts[i] += counts[i-1]

    # Rewrite values to the temp sorted array
    for i in range(len(arr)-1, -1, -1):
        counts[arr[i]] -= 1
        temp[counts[arr[i]]] = arr[i]

    # Rewrite sorted values to the initial array
    for i in range(len(temp)):
        arr[i] = temp[i]

def _max(arr):
    if not arr:
        return None
    max_val = arr[0]
    for i in range(1, len(arr)):
        if arr[i] > max_val:
            max_val = arr[i]
    return max_val

def _min(arr):
    if not arr:
        return None
    min_val = arr[0]
    for i in range(1, len(arr)):
        if arr[i] < min_val:
            min_val = arr[i]
    return min_val

Kilka testów
```

```
In (65): test_sort(counting_sort, range=(0, 100), samples=100, failed_only=True)

Sorting algorithm is correct
Passed tests in total: 100/100
```

Implementacja algorytmu #4 (modyfikuje tablicę)

(Wersja dla liczb całkowitych (MOGA BYĆ UJEMNE) bez konieczności wskazywania wartości najmniejszej i największej (po prostu szukamy ich linioowo w pierwszej petli, bo tablica jest nieposortowana))

```
In (66): def counting_sort(arr):
    if arr:
        min_val, max_val = _minmax(arr)
        _counting_sort(arr, min_val, max_val)

def _minmax(arr):
    global_min = global_max = arr[0]
    for i in range(1, len(arr)-1, 2):
        if arr[i] > arr[i+1]:
            if arr[i] > global_max:
                global_max = arr[i]
            if arr[i+1] < global_min:
                global_min = arr[i+1]
        else:
            if arr[i+1] > global_max:
                global_max = arr[i+1]
            if arr[i] < global_min:
                global_min = arr[i]
    return global_min, global_max

def _counting_sort(arr, k: 'the lower bound', m: 'the upper bound'):
    # Allocate memory for required temporary arrays
    counts = [0] * (m - k + 1)
    temp = [None] * len(arr)
    # Count values repetitions
    for val in arr:
        counts[val - k] += 1

    # Modify the counts array to indicate how many values are not greater than the current one
    for i in range(1, len(counts)):
        counts[i] += counts[i-1]

    # Rewrite values to the temp sorted array
    for i in range(len(arr)-1, -1, -1):
        counts[arr[i] - k] -= 1
        temp[counts[arr[i] - k]] = arr[i]

    # Rewrite sorted values to the initial array
    for i in range(len(temp)):
        arr[i] = temp[i]

Kilka testów
```

```
In (67): sorting_functions['Counting Sort (#4 - negative & positive)'] = (counting_sort, {
    'counting_sort': counting_sort,
    'minmax': _minmax
})
```

Kilka testów

```
In (68): test_sort(counting_sort, samples=100, failed_only=True)

Sorting algorithm is correct
Passed tests in total: 100/100
```

Radix Sort

Założenia, aby korzystanie z algorytmu było opłacalne

- Dane wejściowe muszą się dać podzielić na poszczególne fragmenty, odpowiadające pojedynczej cyfrze (lub pojedynczemu znakowi w przypadku sortowania tekstu).
- Algorytm pomocniczy, przy pomocy którego będziemy sortować wartości według znaków (poszczególne cyfry), musi mieć niską złożoność i przede wszystkim, być stabilny (tylko wtedy Radix Sort działa prawidłowo).

Złożoność sortowania

Złożoność czasowa

Każdy przypadek

$O(d \cdot (n + b))$

d = $\log_b(k)$, gdzie k - maksymalna wartość w sortowanej tablicy, b - liczba elementów w sortowanej tablicy, n - podstawa systemu liczebowego, w jakim odbywa się sortowanie (bo tyle elementów będzie miała tablica, służąca do zliczania powtórek wartości). Radix Sort używany jest do sortowania danych w pamięci (w przypadku sortowania tekstu, jako podstawa przyjmujemy różnicę między największym i najmniejszym kodem ASCII litera alfabetycznym (plus 1), wyklucza wtedy do liczba 26, ponieważ tyle jest małych liter alfabetu łacinskiego. Samo sortowanie wygląda jednak nieco inaczej niż w przypadku sortowania liczb, co zostało zaprezentowane w jednej z poniższych implementacji)

UWAGA

Najlepsza złożoność obliczeniowa uzyskamy wtedy, gdy $b \approx n$, ponieważ wówczas $d \approx \log_b(k)$ ma niewielką wartość i równocześnie suma $n + b \approx 2 \cdot n$, a więc 2-krotne zwiększenie czynnika $(n + b)$ spowodowało nam znacznie zmniejszenie czynnika d. Nie możemy jednak w nieskończoność zwiększać b, ponieważ wtedy nie będziemy mogli użyć uniwersalnego algorytmu sortowania, jakim jest Insertion Sort (dla małych danych największą wartość będzie miało b, a więc zwiększenie b spowodowało nam zwiększenie d). W rzeczywistości, która wtedy, mimo iż $d = 0$, będzie wysoka, ponieważ będziemy musieli zaokrąglić $O(n + b)$ pamięci, a alokacja odbywa się w czasie proporcjonalnym do alokowanego miejsca, czyli w tym przypadku będzie to $O(n + b)$.

Przy założeniu, że $b = \theta(n)$, otrzymujemy złożoność: $O(d \cdot (n + n)) = O(d \cdot n)$. Jeżeli również mamy stałe górne ograniczenie na wielkość liczb (tzn. k nie przekracza pewnej ustalonej wartości), z dobrym przybliżeniem można przyjąć, że $O(d \cdot (n + n)) = b \cdot \theta(n) = O(\log_b(k)) \approx O(1)$ (w notacji dużego O tak zawsze k = $O(1)$, jeżeli k - ustalone, ale tu dodatkowo bierzemy logarytm o podstawie n z liczbą k, więc tym bardziej wartość $d = \log_b(k)$ jest bliska jedynce). Otrzymujemy wówczas:

$$O(d \cdot n) = d \cdot n = \log_b(k) \cdot k = \text{const.} \Rightarrow d = O(1) = O(n)$$

Złożoność pamięciowa

Każdy przypadek

$O(n + b)$

n - liczba sortowanych elementów (tyle elementów będzie miała tablica temp), b - podstawa systemu liczebowego (tyle elementów będzie miała tablica count). Podstawa ta może być dowolna (nie musimy koniecznie sortować liczb dziesiętnych, biorąc za podstawę systemu liczebowego wartość b = 10).

UWAGA

Dla $b = \theta(n)$, otrzymujemy: $O(n + n) = O(n)$.

Stabilność

Stabilny Jest to jedna z cech tego algorytmu, że żeby działał on prawidłowo, do sortowania wybieramy jako algorytm pomocniczy algorytm stabilny, np. Counting Sort.

Czy sortowanie odbywa się w miejscu?

Nie

Zawsze musimy użyć dodatkowej pamięci, która jest zależna od danych wejściowych (tu od liczby elementów do posortowania oraz liczby wiader, która również zależy od wielkości danych wejściowych).

Implementacja algorytmu #1 (z pomocą Insertion Sorta)

(Wersja dla dowolnych liczb rzeczywistych)

```
In (74): def bucket_sort(arr, k: 'threshold' = 24):
    if len(arr) <= k:
        insertion_sort(arr)
    else:
        # Create buckets
        m = int(2/3 * k)
        buckets_count = len(arr) // m + 1
        min_val, max_val = _minmax(arr)
        buckets = [[] for _ in range(buckets_count)]
        # Distribute values to the proper buckets
        for val in arr:
            bucket_idx = int((val - min_val) / (val_interval - .5)) # Round down in order not to overflow an array
            buckets[bucket_idx].append(val)
            # Sort each bucket separately
            for bucket in buckets:
                insertion_sort(bucket)

        # Rewrite sorted values from buckets to the initial array
        i = 0
        for i in range(len(arr)):
            if i % m == 0:
                max_val = arr[i]
            elif arr[i] > max_val:
                max_val = arr[i]
            return i, min_val, max_val

def _minmax(arr, i, j):
    arr[i], arr[j] = arr[j], arr[i]

def _counting_sort(arr, begin_idx, end_idx, digit_place, base):
    # Allocate memory for required temporary arrays
    counts = [0] * base
    result = [None] * (end_idx - begin_idx + 1)
    # Count digits
    for i in range(begin_idx, end_idx + 1):
        digit = (arr[i] // digit_place) % base
        counts[digit] += 1

    # Modify the counts array to indicate how many digits are not greater than the current one
    for i in range(1, base):
        counts[i] += counts[i-1]

    # Rewrite values to the result sorted array
    for i in range(end_idx, begin_idx - 1, -1):
        digit = (arr[i] // digit_place) % base
        counts[digit] -= 1
        result[counts[digit]] = arr[i]

    # Rewrite sorted values to the initial array
    for i in range(len(temp)):
        arr[i] = temp[i]

def _max(arr):
    if not arr:
        return None
    max_val = arr[0]
    for i in range(1, len(arr)):
        if arr[i] > max_val:
            max_val = arr[i]
    return max_val

def _min(arr):
    if not arr:
        return None
    min_val = arr[0]
    for i in range(1, len(arr)):
        if arr[i] < min_val:
            min_val = arr[i]
    return min_val

Kilka testów
```

```
In (75): sorting_functions['Bucket Sort (#1 - with Insertion Sort)'] = (bucket_sort, {
    'insertion_sort': insertion_sort,
    'minmax': _minmax
})
```

Kilka testów

```
In (76): # test_sort(bucket_sort, range=(0, 1000, 10000), val_counts=(0, 10_000), samples=1000, failed_only=True)
# test_sort(bucket_sort, samples=100, ints_only=False, failed_only=True)
```


